

学术报告

# 通向 2030 年的 人工智能算力曲线

外推、约束，与最先触及的那堵墙

汇报人

李明

日期

2026 年 8 月

单位

计算科学与人工智能实验室

# 目 录

---

|    |       |                 |
|----|-------|-----------------|
| 01 | 问题    | 把不可证伪的争论换成可计算的量 |
| 02 | 方法    | 锚点不能自己选         |
| 03 | 结果    | 先撞哪一堵墙          |
| 04 | 结论与边界 | 条件命题，不是预测       |

# 01

## PART 01

### | 问题

把不可证伪的争论换成可计算的量

#### “会不会更强”无法证伪

双方对“强”的度量不一致，争不出结果

#### 算力是可算的代理量

有单位、有历史序列、有标度律绑定规模与数据

#### 代价要先讲清

算力不等于能力，最后一节回到这一点

01 问题

02 方法

03 结果

04 结论与边界

## 把问题收窄到单次训练算力，分歧才变得可以计算

为什么选算力：它有明确单位（FLOP），有公开的历史序列，并通过标度律与模型规模、数据量建立定量联系。

收窄的代价：算力不等于能力，两者之间隔着“算力→损失”与“损失→任务表现”两层映射。

收窄的收益：各方的判断可以折算到同一套单位里，分歧从此可以定位而不只是表态。

$$C \approx 6 N D \quad (1)$$

其中 **C** 单次训练算力； **N** 参数量； **D** 训练 token 数。

系数 6

来自前向与反向传播中每个参数每个 token 的乘加次数计数。三个量绑定后，给定其中两个即可推出第三个。

**FLOP**

单位明确

**20 年**

公开历史序列

**2 层**

到能力的映射

算力曲线在 2010 年折过一次，倍增期由 20 个月缩到 6 个月




图 1 按已发表的倍增周期与 2030 年结论构造的算力轨迹（非逐模型实测点）

对数坐标上斜率抬了 3.3 倍： 这一加速不是硬件单方面的贡献，而是硬件、资本投入与工程并行度共同作用，因此没有像摩尔定律那样明确的物理下限可依。

Sevilla 等 (2022) arXiv:2202.05924 ; Epoch AI (2024)

# 02

## PART 02

# 方法

锚点不能自己选

### 等比例配比

算力预算固定时，参数量与 token 数应同步放大

### 指数外推

对数坐标下是直线，折点即倍增期变化处

### 锚点取自己发表结论

自选起点会把结论悄悄写进假设里

01 问题

**02 方法**

03 结果

04 结论与边界

# 三个关系式，把标度律、外推与锚点串成一条可复核的链

$$N_{\text{opt}} \propto C^{1/2}, \quad D_{\text{opt}} \propto C^{1/2} \tag{2}$$

其中  $N_{\text{opt}}$  计算最优参数量；  $D_{\text{opt}}$  计算最优 token 数。

式 (2) 的来源： 训练四百余个模型后得到的结论——算力预算固定时，参数量与 token 数应等比例放大。

$$C(t) = C(t_0) g^{t - t_0} \tag{3}$$

其中  $g$  年增倍数；  $t_0$  基准年。

式 (3) 的形态： 对数坐标下是直线；轨迹呈折线，只因为倍增期在某些年份发生了变化。

式 (4) 是关键： 本文不自选历史起点，两个锚点都取自同一份公开报告，基准年由它们反推得到。

$$C_{2024} = \frac{C_{2030}}{g^6} = \frac{2 \times 10^{29}}{4^6} \approx 4.9 \times 10^{25} \tag{4}$$

其中  $C_{2024}$  由两个已发表锚点反推的基准。

# 自选起点会把结论写进假设：第一版外推低了六个数量级



$4.9\times 10^{25}$

反推的 2024 年基准  
FLOP

$10^{25}$

公开报告的独立陈述  
逾 30 个模型达此量级

一致性校验

反推值与该报告另一处独立陈述在数量级上相容。两个来源互不依赖，因此这条校验是有效的。

一般性教训： 外推里最容易出错的不是增速，是起点。起点一旦自选，结论就被悄悄写进了假设，而且错得毫无痕迹。

# 03

PART 03

## | 结果

先撞哪一堵墙

四道天花板差三个数量级

“会不会撞墙”不是有内容的问题

电力最先咬合

其次是芯片产能

数据墙其实更早

把两篇文献联立才看得见

01 问题

02 方法

**03 结果**

04 结论与边界

# 四类约束的上限相差三个数量级，问题该换成 “先撞哪一堵”




图 2 四类约束单独作用时 2030 年所允许的训练算力上限

跨度极不对称： 电力（单一园区）上限区间  $1 \times 10^{28}$ — $3 \times 10^{29}$ ，延迟墙则在  $3 \times 10^{30}$ — $1 \times 10^{32}$ ，中位相差约两个半数量级。在这个尺度差面前，把 “会遇到物理瓶颈” 当作单一命题讨论是没有内容的。

# 四道天花板的量化口径与对应上限

| 约束          | 资源口径                                         | 允许的训练算力 / FLOP                      |
|-------------|----------------------------------------------|-------------------------------------|
| 电力 · 单一园区   | 1—5 GW                                       | $1\times10^{28}$ — $3\times10^{29}$ |
| 电力 · 跨地域分布式 | 2—45 GW                                      | $2\times10^{28}$ — $2\times10^{30}$ |
| 芯片产能        | 2 000 万 — 4 亿张 H100 等效                       | $1\times10^{29}$ — $5\times10^{30}$ |
| 数据存量        | $4\times10^{14}$ — $2\times10^{16}$ 有效 token | $6\times10^{28}$ — $2\times10^{32}$ |
| 延迟墙         | 现有硬件                                         | $3\times10^{30}$ — $1\times10^{32}$ |
| 综合结论        | —                                            | $2\times10^{29}$                    |

读法： 综合结论落在电力（单一园区）区间的上四分之一处，略高于芯片产能区间的下沿——这正对应“电力最先咬合、芯片产能其次”的判断。

## 把等比例配比与文本存量联立，数据墙在 $2.7 \times 10^{28}$ 就到了




图 3 计算最优配比下  $N$  与  $D$  随算力的走向，及其与公开文本存量的交点

$$C_{\text{data}} = C_0 \left( \frac{D_{\text{data}}}{D_0} \right)^2 \approx 2.7 \times 10^{28} \quad (5)$$

解出的交点：令  $D$  等于约  $3 \times 10^{14}$  token 的公开人类文本存量，由式 (2) 反解得  $C \approx 2.7 \times 10^{28}$  FLOP。

它比想象的早：该值仅为综合结论  $2 \times 10^{29}$  的 0.14 倍；按 4×/ 年折算，比电力墙提前约 1.4 年。

## 与上一页的“数据不是紧约束”并不矛盾，差别全在口径

### 多模态有效 token 口径

$4 \times 10^{14}$  —  $2 \times 10^{16}$ ，把图像、音频、视频与质量加权后的重复利用都计入。结论：数据不是紧约束。

### 纯文本存量口径

约  $3 \times 10^{14}$  token。结论：在  $2.7 \times 10^{28}$  FLOP 处即告失效。

**0.14×**

数据墙 / 综合结论

**1.4 年**

比电力墙提前

### 精确表述

纯文本路线在  $2.7 \times 10^{28}$  FLOP 附近失效。继续放大必须依赖多模态语料、合成数据或数据效率改进——这三条从可选项变成必需项的时点，由式 (5) 给出。

该问哪个问题：不是“数据够不够用”，而是“按哪个口径算、这个口径对应的技术路线是否成立”。口径一换，结论就反向。

## 六次方让结果对增速极度敏感：4.0 与 3.0 差了近五倍




图 4 2030 年可达算力对持续年增倍数的敏感性

$g = 3.0$  : 2030 年只有  $3.6 \times 10^{28}$ ，不足综合结论的五分之一。

$g = 4.0$  : 恰为  $2 \times 10^{29}$ ，即公开报告的判断值。

$g = 4.28 / 5.14$  : 分别触及电力（单一园区）上限与芯片产能中位。

### 推论

对 2030 年状态的任何断言，实质上都是对“年增速能否维持六年”的断言。

为什么这么敏感：六年复利意味着六次方—— $g$  变动四分之一，2030 年的结果就变动一个数量级。历史上该增速已维持十余年，但维持它所依赖的资本与电力扩张已进入新的量级。

结果

## 约束的物理载体：电力接入以电网规划计，产能扩张以年计



图 5 数据中心机房：供电与散热能力是最先咬合的约束 (CC0 / rawpixel)




图 6 晶圆厂洁净室：产能无法在需求出现后一两年内响应 (STMicroelectronics (original... / CC BY / Wikimedia Commons)

为什么电力最先咬合： 1—5 GW 的园区级功率相当于一座中型核电机组的输出，其接入周期由电网规划决定，而不由芯片供应决定。

# 04

## PART 04

# | 结论与边界

条件命题，不是预测

---

### 三条结论

轨迹、约束排序、数据墙位置

---

### 三处不确定性

锚点、配比假设、口径

---

### 最重要的限定

算力不等于能力

01 问题

02 方法

03 结果

**04 结论与边界**

## 结论：三条都是条件命题，条件是增速能否维持六年

- 1. 轨迹：** 以已发表的两个锚点反推，2024 年基准约  $4.9 \times 10^{25}$  FLOP；维持年增 4 倍六年后达到  $2 \times 10^{29}$  FLOP。每一段都可由公开数值复核，不含自选参数。
- 2. 约束排序：** 四类约束的上限相差三个数量级以上，最先咬合的是电力，其次是芯片产能。因此该问的是“先遇到哪一个、在什么算力水平上遇到”。
- 3. 数据墙：** 纯文本路线在  $2.7 \times 10^{28}$  FLOP 处失效，比电力约束提前约 1.4 年。多模态语料、合成数据与数据效率改进因此是前置条件，不是加分项。

**边界** 以上全部取决于年增速能否维持六年，而这一条本报告无法回答。外推的价值不在于给出答案，在于把答案所依赖的假设摆到明处。

## 必须写明的局限：算力与能力之间隔着两层映射

1

### 第一层：算力 → 损失

有稳定的幂律形式，但幂指数意味着收益递减——算力涨一个数量级，损失的改善远小于一个数量级。

2

### 第二层：损失 → 任务表现

更不稳定。同一损失水平下不同任务差异很大，推理时计算的引入进一步削弱了对应关系。

因此结论只能说规模： $2 \times 10^{29}$  FLOP 支撑的陈述是“规模上的增长空间”，而不是“能力上的必然提升”。

原报告也是这么表述的：它把结论说成“规模差距相当于 GPT-2 到 GPT-4 之间的差距”——这是关于规模的类比，不是关于能力的承诺。

### 三处不确定性

锚点精度完全继承自两个已发表量；式 (2) 假定严格等比例配比，实际偏离会让数据墙更早到来；纯文本与多模态两种口径给出方向相反的结论。

听报告时的判据：凡是把 FLOP 数字直接说成能力水平的，中间那两层映射一定被跳过了——可以据此判断一个预测是否值得采信。

## 参考文献

- [1] Epoch AI. Can AI scaling continue through 2030? 2024. [epoch.ai/blog/can-ai-scaling-continue-through-2030](https://epoch.ai/blog/can-ai-scaling-continue-through-2030).
- [2] HOFFMANN J, BORGEAUD S, MENSCH A, et al. Training compute-optimal large language models[C]. NeurIPS, 2022, 35. arXiv:2203.15556.
- [3] KAPLAN J, MCCANDLISH S, HENIGHAN T, et al. Scaling laws for neural language models[EB/OL]. 2020. arXiv:2001.08361.
- [4] SEVILLA J, HEIM L, HO A, et al. Compute trends across three eras of machine learning[EB/OL]. 2022. arXiv:2202.05924.
- [5] VILLALOBOS P, HO A, SEVILLA J, et al. Will we run out of data? Limits of LLM scaling based on human-generated data[C]. ICML, 2024. arXiv:2211.04325.

# 致 谢

---

---

指导与合作

**实验室同事**

在锚点选取与口径差异上的讨论

**Epoch AI 等四个研究组**

本报告全部外部数值的来源

---

项目与平台支持

公开文献与开放数据

本报告不产生新数据，只把已发表的判断放进同一套单位里。

# 讨论与提问

先撞的不是电力墙，是数据墙——前提是纯文本路线不变。

联系方式

liming@example.edu

图表与脚本

本报告的全部图由公开数据复算