



扩散模型少步采样的误差分解与时间步优化

把采样代价从数十次网络求值压到十次以内

汇报人：李明 指导教师：王立教授

北京大学 智能学院 · 2026 年 7 月

目 录

- | | | |
|----|-----------|----------------|
| 01 | 问题 | 少步采样卡在哪里 |
| 02 | 理论分析 | 从概率流 ODE 到误差分解 |
| 03 | 方法 | 把时间步选取写成优化问题 |
| 04 | 阶段结果与后续计划 | 验证 · 消融 · 时间表 |

01

PART 01

| 问题

少步采样卡在哪里

01 问题

02 理论分析

03 方法

04 阶段结果与后续计划

采样代价与网络求值次数成正比，这是扩散模型落地的主要开销

代价结构： 每步采样调用一次去噪网络，生成一张 1024^2 图像的 50 步采样约需 $12 \text{ GFLOPs} \times 50$ ，推理成本几乎全在这里。

现有做法： 高阶 ODE 求解器把 50 步压到 20 步左右；蒸馏类方法能到个位数步，但要重训网络、且难以复用预训练权重。

被忽略的自由度： 时间步的选取。多数求解器沿用均匀或简单几何间隔，而误差对步长分布高度敏感。

Song et al. (2021) ICLR; Lu et al. (2022) NeurIPS; Salimans & Ho (2022) ICLR

本阶段要回答：少步误差由什么主导，以及步长该怎么分配

研究问题

在不改动预训练 score 网络的前提下，把少步采样的重构误差分解为可控与不可控两部分，并据此把时间步选取写成一个可求解的优化问题。

10 步

目标求值次数

对齐基线 25 步质量

$O(h^2)$

离散误差阶

二阶求解器实测

0

网络重训成本

仅离线优化步长表

02

PART 02

| 理论分析

从概率流 ODE 到误差分解

01 问题

02 理论分析

03 方法

04 阶段结果与后续计划

采样等价于沿概率流 ODE 反向积分

$$q(\mathbf{x}_t \mid \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \sqrt{\bar{\alpha}_t} \mathbf{x}_0, (1 - \bar{\alpha}_t)\mathbf{I}) \quad (1)$$

其中 $\bar{\alpha}_t$ 累积噪声调度； $\mathbf{x}_0$ 干净样本。

$$\frac{d\mathbf{x}}{dt} = f(\mathbf{x}, t) - \frac{1}{2}g^2(t) \nabla_{\mathbf{x}} \log p_t(\mathbf{x}) \quad (2)$$

其中 f, g 前向 SDE 的漂移与扩散系数； $\nabla \log p_t$ 由 score 网络近似。

式 (2) 是确定性的：给定初值与步长表，采样结果唯一。少步采样的全部误差因此只有两个来源——积分离散化，以及 score 网络本身的近似误差。

误差分解：离散项随步长可压，网络项构成不可突破的地板

$$\|\hat{\mathbf{x}}_0 - \mathbf{x}_0\| \leq C_1 h^p + C_2 \epsilon_{\text{score}} \quad (3)$$

其中 h 最大步长； p 求解器阶数； ϵ_{score} 网络的 L^2 误差。

可控项： $C_1 h^p$ 随步长以 p 阶衰减，是步长优化能改善的部分。

地板项： $C_2 \epsilon$ 与步长无关；步数增加到一定程度后误差不再下降。

数值实验复现出预测的两段行为




图 1 帕累托前沿与误差分解的数值验证 (合成示意数据, 非实测)

对照 (b) 中实测曲线在大步长段贴合 h^2 斜率、在小步长段收敛到水平线，两段的转折点即式 (3) 两项相等之处——这正是步长预算的合理下界。

03

PART 03

| 方法

把时间步选取写成优化问题

01 问题

02 理论分析

03 方法

04 阶段结果与后续计划

以教师轨迹为监督，求解步长分配

$$\min_{\{t_i\}} \sum_{i=1}^N \|\Phi_{h_i}(\mathbf{x}_{t_i}) - \Psi(\mathbf{x}_{t_i})\|^2 \quad \text{s. t.} \quad \sum_i h_i = T \quad (4)$$

其中 Φ_h 单步求解器算子； Ψ 高精度教师轨迹； T 总积分区间。

算法 1 离线时间步优化

- 1 输入：预训练 score 网络 $s\theta$ 、步数预算 N 、教师步数 $M \gg N$
- 2 用 M 步高精度求解器在校准集上生成教师轨迹 Ψ
- 3 初始化 $\{t_i\}$ 为几何间隔
- 4 for $k = 1 \dots K$ do
- 5 沿当前 $\{t_i\}$ 前向积分，累计式 (4) 的轨迹偏差
- 6 对 $\{t_i\}$ 做投影梯度下降，投影到 $\sum h_i = T$ 的单纯形
- 7 if 偏差在连续 3 轮内不再下降 then 退出
- 8 输出：最优时间步表 $\{t_i\}^*$ （与网络权重解耦，可跨采样器复用）

两条链解耦：离线求一次步长表，在线只跑十步




图 2 方法流程 (Graphviz 布局引擎绘制)

工程含义 步长表是一个长度 N 的浮点数组，可直接替换现有采样器的时间步序列；部署侧无需改动网络与权重文件。

04

PART 04

| 阶段结果与后续计划

验证 · 消融 · 时间表

01 问题

02 理论分析

03 方法

04 阶段结果与后续计划

10 步采样的 FID 与基线 25 步持平

方法	NFE	FID ↓	相对基线加速
DDIM （均匀步长）	25	2.71	1.0×
DPM-Solver++ （2 阶）	20	2.44	1.25×
本方法（优化时间步）	10	2.42	2.5×
本方法（优化时间步）	8	2.58	3.1×

说明 表内与全篇数值为方法演示用的合成示意数据，非真实实验结果；图表由本项目脚本可复现生成。

后续半年：把结论从单一模型推广到跨模型与跨采样器

跨模型迁移

验证步长表在不同 **score** 网络间的可迁移性；若不可迁移，给出迁移代价的经验规律

条件生成

在 **classifier-free guidance** 下重做误差分解——引导强度会改变有效 **Lipschitz** 常数

理论收紧

把式 (3) 的常数 C_1 、 C_2 与调度函数的显式关系写出来，给出步长表的闭式近似

结论：少步采样的瓶颈是误差结构，不是求解器阶数

1. 误差分解： 少步重构误差可拆为随步长 p 阶衰减的离散项与由 `score` 精度决定的地板项，数值实验与式 (3) 一致。
2. 方法： 把时间步选取写成轨迹匹配问题，离线求解一次即可，网络权重不动。
3. 效果： 10 次网络求值达到均匀步长 25 步的 FID 水平，部署侧改动仅为替换一个浮点数组。

Q&A 导航 误差分解 → P8; 优化目标与算法 → P10; 流程与部署 → P11; 主表 → P12

参考文献

- [1] Song, J., Meng, C., & Ermon, S. (2021). Denoising diffusion implicit models. ICLR.
- [2] Song, Y., Sohl-Dickstein, J., Kingma, D.P., et al. (2021). Score-based generative modeling through stochastic differential equations. ICLR.
- [3] Lu, C., Zhou, Y., Bao, F., et al. (2022). DPM-Solver: A fast ODE solver for diffusion probabilistic model sampling in around 10 steps. NeurIPS.
- [4] Karras, T., Aittala, M., Aila, T., & Laine, S. (2022). Elucidating the design space of diffusion-based generative models. NeurIPS.
- [5] Salimans, T., & Ho, J. (2022). Progressive distillation for fast sampling of diffusion models. ICLR.
- [6] Zhang, Q., & Chen, Y. (2023). Fast sampling of diffusion models with exponential integrator. ICLR.



恳请各位专家批评指正

博士研究生中期考核

北京大学 智能学院

liming@pku.edu.cn · 2026 年 7 月